

| | |
|-----------------------------------------------------------|---------------------|
| Sprawozdanie - informatyka w medycynie (IWM) | |
| Prowadzący: <i>dr hab. inż. Szymon Wilk</i> | Grupa: <i>4L</i> |
| Temat Ćwiczeń: <i>Klasyfikacja naczyń krwionośnych</i> | |
| Autorzy: <i>Daniel Zdancewicz[145317]</i> | |

1 Wstęp

1.1 Technologia

Zastosowane technologie

- Server
 - Python 3.10
 - FastAPI
- Przetwarzanie obrazów
 - Numpy
 - sklearn
 - keras
- Klient
 - TypeScript
 - SolidJS

1.2 Opis funkcjonalności

- Wstępne przetwarzanie obrazu (rozmycia, wyostżenia, normalizacja) – 3.0
- Wyodrębnienie naczyń krwionośnych – 3.0
- Poprawa, wygładzenia – 3.0
- Wizualizacja naczyń względem oryginału – 3.0
- Analiza skuteczności (accuracy, sensitivity, specificity) – 3.0
- Wykorzystanie modelu głębokiej sieci neuronowej – 5.0
- Analiza skuteczności sieci neuronowej
- Wizualizacja efektów użycia sieci neuronowej – 5.0

2 Opis zastosowanych metod

2.1 Model tradycyjny (3.0 – obowiązkowy)

Kroki:

1. Ekstrakcja kanału zielonego
2. Wyostwienie
3. Normalizacja histogramu
4. Alogrytm Sato
5. Założenie maski
6. Decyzja binarna z progiem 0.25

Uzasadnienie: Sato dawał najlepsze wyniki, normalizacja jest podstawowym krokiem

2.2 Model drzewa decyzyjnego (4.0 – dodatkowy)

Model - klasyfikator drzewiasty o głębokości 8 Przetwarzanie wczesne, takie same jak dla modelu tradycyjnego:

- Ekstrakcja kanału zielonego
- Wyostwienie
- Normalizacja histogramu
- Alogrytm Sato
- Założenie maski
- pomniejszenie obrazu do skali 0.2 (oszczędzanie czasu)
- Wykorzystanie klasyfikatora na każdym pikselu

2.2.1 Trening Modelu

- Utworzenie generatora wycinków o wielkości 5
- Metryki treningowe jako pierwszych 3 momenty wycinków oraz wynik na podstawie maski eksperckiej

Uzasadnienie: Wykorzystanie klasyfikatora drzewiastego wspomaga przetwarzanie klasyczne

2.3 Model głębokiej sieci neuronowej (5.0 – dodatkowy)

Model - UNET - o dropout'cie równym 0.1 i metodą aktywacji ReLU

Wytrenowany model osiągnął celność 95.1%

2.3.1 Trening Modelu


- Zbiór obrazów DRIVE podzielony na zbiór treningowy i walidacyjny
- Obrazy podawane 3 kanałowe bezpośrednio do modelu
- Wczesne przetwarzanie obrazów treningowych przez przypadkowe
 - Rotacje
 - Przesunięcia
 - Przybliżenia
 - Sekcjonowanie
 - Obracania
 - Podbicia/obniżenia saturacji
 - Podbicia/obniżenia kontrastu

3 Aplikacja



Rysunek 1: Widok aplikacji

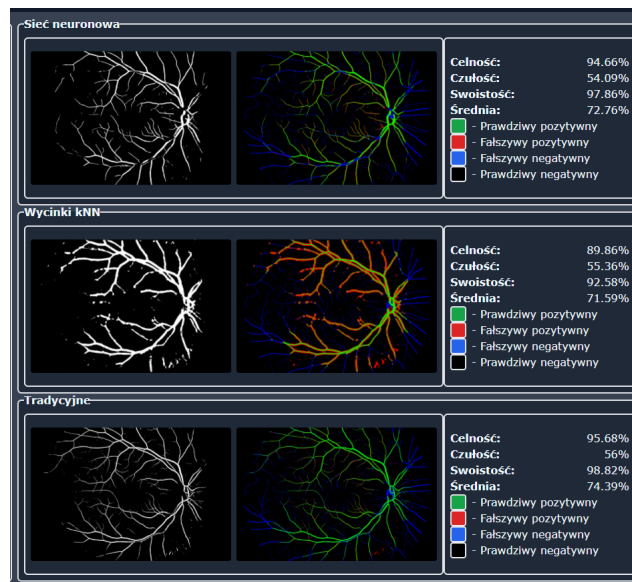
4 Wyniki eksperymentu



Rysunek 2: Analiza dla cukrzyka - 1



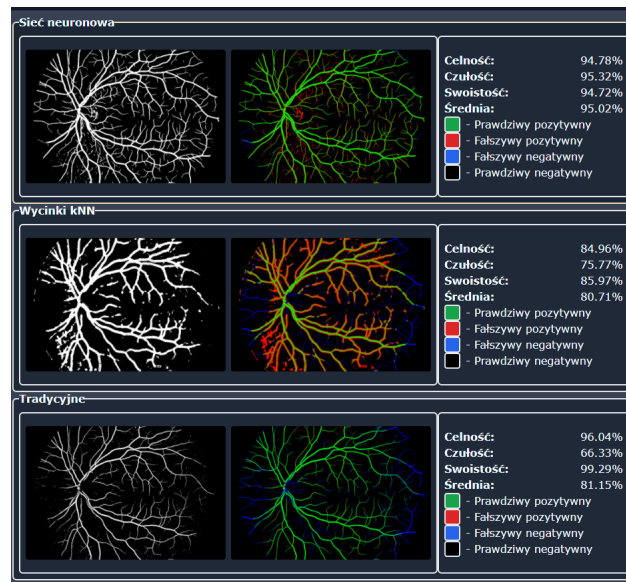
Rysunek 3: Analiza ekspercka dla cukrzyka - 1



Rysunek 4: Analiza dla jaskra - 15



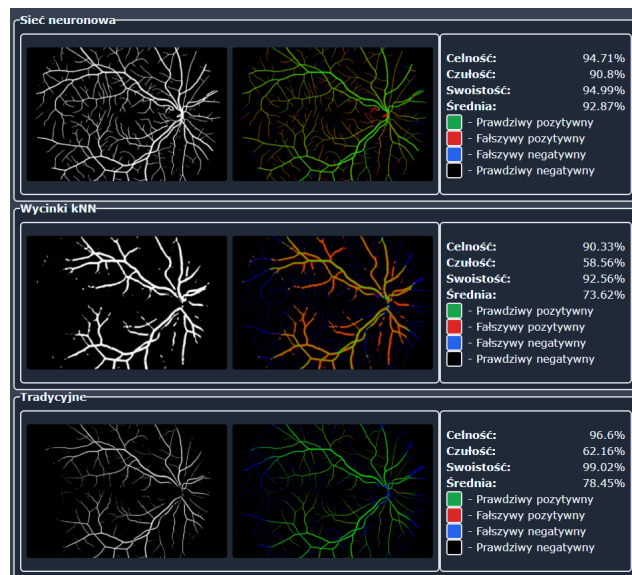
Rysunek 5: Analiza ekspercka dla jaskra - 15



Rysunek 6: Analiza dla zdrowe - 2




Rysunek 7: Analiza ekspercka dla zdrowe - 2



Rysunek 8: Analiza dla jaskra - 10



Rysunek 9: Analiza ekspercka dla jaskra - 10



Rysunek 10: Analiza dla cukrzyk - 3



Rysunek 11: Analiza ekspercka dla cukrzyk - 3